PROPUESTA TÉCNICA Y ECONÓMICA

MÓDULO 3: AGENTE VIRTUAL ENCARNADO "ALEXIA"

Proyecto TransLúcidas — Arquitectura WebGL Mobile, Voz e Integración RAG

Fecha:
Proponente:
Versión Ref.: Doc. Preliminar v0.1
Moneda: COP (Ref. USD)

1. RESUMEN EJECUTIVO Y JUSTIFICACIÓN DE ARQUITECTURA

La presente propuesta responde a los requerimientos del **Módulo 3 (Agente conversacional virtual encarnado: Alexia)** y la sección 12 del documento preliminar. Dado que la plataforma prioriza el **acceso desde dispositivos móviles** (M1-RF-05, RNF-02) y el **bajo consumo de datos** (sección 4.2.3), se descarta el uso de tecnologías de renderizado en servidor como *Unreal Engine MetaHuman con Pixel Streaming* o microservicios GPU dedicados 24/7, los cuales consumirían gigabytes de video por usuario y elevarían los costos fijos mensuales a más de $400 USD. En su lugar, se propone una arquitectura ligera en el navegador basada en **WebGL (Three.js)** que descarga el avatar comprimido una única vez (3 a 8 MB en caché) y transmite exclusivamente paquetes ligeros de audio y metadatos de animación.

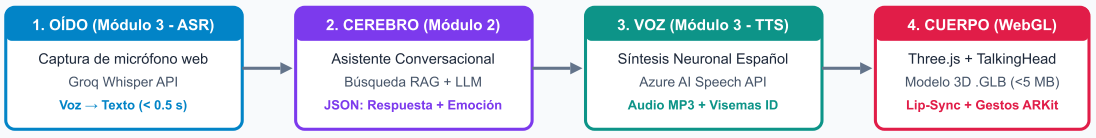


Figura 1. Arquitectura de interoperabilidad (M3-RF-02 y Sección 5.1): Alexia delega la inteligencia documental al Módulo 2 (RAG) y transforma la salida en una experiencia multimodal eficiente.

2. STACK TECNOLÓGICO PROPUESTO

- **Motor Gráfico Web (M3-RF-01):** `Three.js` / `React Three Fiber` integrado con la librería especializada `TalkingHead` para control de cámara, iluminación optimizada en móviles, parpadeo autónomo y sincronización labial.
- **Modelado y Estándar del Avatar (M3-RF-07, M3-RF-08):** Personaje 3D en formato `.GLB` con compresión geométrica *Draco* y texturas *KTX2*. Incluye esqueleto compatible con animaciones corporales de *Mixamo*, **15 visemas de Oculus** para articulación fonética y **52 Blendshapes de ARKit** para expresión emocional.
- **Reconocimiento del Habla (ASR - M3-RF-04, M3-RF-05):** `OpenAI Whisper Large-v3` ejecutado sobre infraestructura `Groq` para transcripción instantánea en español con alta tolerancia a acentos locales y modismos.
- **Síntesis de Voz y Visemas (TTS - M3-RF-06, M3-RF-07):** `Azure AI Speech Neural`, que genera en una sola petición tanto el flujo de audio comprimido como el arreglo temporal exacto de fonemas/visemas, evitando cálculos pesados de CPU en teléfonos de gama media o baja.

3. OPCIONES DE PRESUPUESTO POR NIVEL DE IMPLEMENTACIÓN (SECCIÓN 4.3.3)

De acuerdo con la estructura solicitada en el documento de requerimientos, se presentan tres opciones escalonadas (calculadas sobre una tarifa base de referencia de **$25.000 COP / hora**):

Componente / Criterio	Opción 1: Nivel 1 Prototipo Funcional	Opción 2: Nivel 2 Agente Expresivo (Recomendado)	Opción 3: Nivel 3 Experimental Avanzado
Diseño y Validación 3D de Alexia (4.3.1)	Modelo `.GLB` base optimizado (<5 MB) con **1 ronda** de ajuste estético (colores/atuendo).	Diseño 3D a medida (Blender/CC4) con **hasta 3 rondas de co-diseño** y validación comunitaria.	Todo el Nivel 2 + ajustes finos de morfología facial tras pruebas de aceptación piloto.
Sincronización Labial (M3-RF-07)	Movimiento básico de mandíbula guiado por amplitud/volumen de onda del audio.	**Lip-Sync fonético preciso** mapeando los 15 visemas de Oculus con tiempos de Azure TTS.	Lip-Sync fonético con *streaming por fragmentos (chunking)* para respuesta en < 1.5 seg.
Expresiones y Gestos (M3-RF-08)	Postura base en bucle (*Idle*) y parpadeo automático natural.	**5 emociones faciales ARKit + 4 gestos corporales** activados según el contexto del RAG.	Transiciones suaves entre animaciones y micro-expresiones de escucha activa.
Voz (ASR/TTS) e Interfaz (M3-RF-03 a 10)	Captura por turnos, transcripción Whisper, voz Azure, conexión a Módulo 2 y chat alternativo.	Todo el Nivel 1 + conector JSON estructurado con Módulo 2 para lectura de tono emocional.	**Adaptación de jerga/acentos** (diccionario fonético ASR) + panel de métricas anónimas.
Pruebas Piloto y Seguridad	Pruebas funcionales e implementación de límite de 15 consultas/hora por IP.	Pruebas integrales en móviles Android/iOS y manejo controlado de fallos de red.	Incluye **25 horas de acompañamiento técnico** en talleres con investigadores y usuarios.
Esfuerzo y Duración	**90 horas** (4 semanas)	**165 horas** (7 a 8 semanas)	**235 horas** (10 a 11 semanas)
INVERSIÓN (Pago Único)	**$2.250.000 COP** (Aprox. $535 USD)	**$4.125.000 COP** (Aprox. $980 USD)	**$5.875.000 COP** (Aprox. $1.400 USD)

4. COSTOS OPERATIVOS RECURRENTES ESTIMADOS (RNF-10)

Estimación Mensual de Infraestructura y APIs Externas (A cargo del Proyecto)

Dimensionado para un escenario piloto de hasta **50 usuarios concurrentes** y **2.000 interacciones de voz al mes** (duración promedio de 30 segundos / ~400 caracteres por respuesta):

- **Alojamiento Web y CDN del Avatar (Cloudflare Pages / Vercel): $0 USD / mes** (cubierto por capa gratuita; el archivo `.GLB` se almacena en caché local del teléfono del usuario tras la primera visita).
- **Reconocimiento del Habla (ASR — Groq Whisper Large-v3): $2 a $4 USD / mes**.
- **Síntesis de Voz Neural + Visemas (TTS — Azure AI Speech): $0 a $12 USD / mes** (Azure